

Pho2Vis：基于预训练模型与物理信息增强的 能见度估计方案

江丰捷^a, 黄柏喻^b, 浦皓天^c, 张轩^d

^a 北京大学, 物理学院

^b 北京大学, 数学科学学院

^c 北京大学, 信息管理系

^d 北京大学, 信息管理系

2024.6

摘要

能见度估计在保障交通运输安全中的关键作用, 特别是在雾霾、雨、沙尘暴等极端天气条件下。能见度骤降会带来安全隐患, 准确的能见度评估对于预防交通事故、保护人员安全及优化智能交通系统至关重要。本研究重点介绍了深度学习模型在能见度估计中的应用工作, 如 InceptionV3、DenseNet121 和 Vision Transformer (ViT), 这些模型结合了北京大学本地图像数据和能见度相关物理信息进行多模态融合, 以提高预测精度和鲁棒性。实验结果显示, 经过微调的 InceptionV3 模型表现较优, 未经微调的 ViT 模型也表现较好。未来研究方向包括优化模型结构、扩大数据集、探索更多物理特征的融合以及改进数据处理策略。项目在 <https://github.com/xueshenjiang/Pho2Vis> 开源。

目录

1	引言	3
1.1	能见度的意义	3
1.2	定义和意义	3
2	相关文献	4
2.1	以往的能见度估计方案	5
2.2	现有的深度学习方法	5
3	研究方法	6
3.1	数据集介绍	7
3.2	模型介绍	9
3.2.1	基于 InceptionV3 的微调	9
3.2.2	基于 DenseNet121 预训练模型搭建的网络	10
3.2.3	基于 vit-base-patch16-224 预训练模型搭建的网络	11
4	实验过程	11
5	结果与分析	12
5.1	实验指标	12
5.2	实验结果	12
5.3	消融实验	13
6	后续工作	15
7	小组分工	15
8	总结	16

1 引言

1.1 能见度的意义

在恶劣的天气条件下，能见度的显著降低往往会对交通运输安全构成严重威胁。无论是雾、霾、大雨还是沙尘暴，它们都能极大地限制人们的视线范围，进而增加交通事故的风险。以河南郑州附近一次涉及 200 多辆车的高速公路连环车祸为例¹，那次事故正是由于浓雾突然袭来，导致能见度急剧下降，最终造成了不幸的人员伤亡。这一事件不仅令人痛心，也引发了人们对中国城市中心空气质量和能见度的持续关注。它深刻地表明，如何准确而有效地从用户个人角度估计能见度已经变得至关重要。

在智能车辆快速发展的背景下，单个摄像机和算法对能见度的估算更是成为了确保道路安全和有效交通管理的关键环节。我们知道，智能车辆通常配备了先进的驾驶员辅助系统（ADAS），这些系统通过收集和分析车辆周围环境的信息，为驾驶员提供必要的辅助，以提高行车安全性。而在这些系统中，准确的能见度估算显得尤为重要 [1]。准确的能见度估算有助于减少不良天气条件导致的交通事故风险。据相关统计数据显示，每年由于雾、霾、大雨等恶劣天气条件引发的交通事故不计其数，这些事故不仅造成了巨大的财产损失，还导致了大量的人员伤亡。而如果我们能够准确地估算出能见度，就可以提前预警驾驶员，让他们及时采取相应的措施，从而降低事故发生的可能性。

综上所述，准确而有效地估计能见度对于确保交通运输安全至关重要。

1.2 定义和意义

根据国际民用航空组织（ICAO）的定义，能见度被定义为“在观察明亮背景时，在地面附近能看见并识别出合适尺寸的黑色物体所能达到的最大距离” [2]。以置于明亮背景下距离观察者 50m 处的一个黑色轮胎为例，假设在观察者与轮胎附近能见度可变，则在能见度分别为无穷大、大于 50m 的有限值和小于 50m 的有限值时，观察者所看到的轮胎图像将如图 1所示。

通常来说能见度不会达到 50m 以下的级别。但是从该例子中可以清晰地得出结论：进行有效而准确的能见度估计可以很好地帮助交通参与者（人或智能驾驶系统）估计道路交通信息。

不过，能见度的概念并非仅限制在地表，而是可以被推广至更高高度的

¹<https://www.cbsnews.com/news/china-pile-up-crash-accident-bridge-fog/>



图 1: 从左到右分别为能见度取不同值时的 50m 处的轮胎视觉效果。能见度值越小，则同一条件下轮胎将越不可分辨。(a) 能见度取无穷大；(b) 能见度为大于 50m 的有限值；(c) 能见度为小于 50m 的有限值。

天空。例如，美国国防大学出版社的一本出版物 [3] 讨论了高空能力的战略重要性，其中包括能见度作为空间和近空间环境中的关键运作因素。

为了将本课程所教授的深度学习模型与应用内容与大气科学领域视觉数据的代表——能见度的估计方案紧密结合，我们小组深入开展了一系列研究。我们首先对深度学习模型在能见度估计方面的应用进行了全面的文献综述，旨在分析该方案的可行性，并在此基础上，我们进一步收集并处理了从北京大学大气与海洋科学系获取的本地数据。随后，我们将详细介绍在这批数据上开展能见度估计方案实验的方法和所得结论。

2 相关文献

首先，我们进行了文献综述，了解能见度的估计方案。如图 2所示，能见度测量方法可以分为三大类，分别为传统方法、统计方法和机器学习方法 [4]。

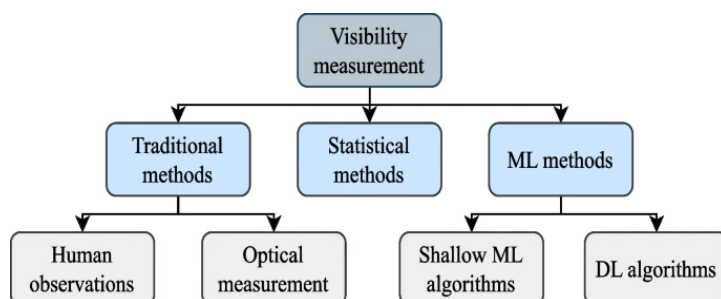


图 2: 现有估计方案分类

2.1 以往的能见度估计方案

早期，监测能见度主要依赖传统方法，如人工和专业观察。专家经过培训后执行观察，可作为设备测量的补充。现仍有人类观察员在某些站点进行观测。另一种常见方法是光学测量，在气象站中使用能见度计自动量化能见度。但因设备价格昂贵且报告延迟，研究人员正寻求更经济高效的测量方法。

许多研究已经开发出统计模型来估计能见度，这些模型通过确定能见度与其他特征之间的关系来实现，这些特征是从气象物理约束中提取的数据中提取的，例如 Koshmieder 定律和 Lambert-Beer 定律。Koshmieder 定律确定了位于一定距离 (d) 的对象的光亮度 (L) 与附近对象的光亮度 (L_0) 之间的关系。表面光亮度可以通过以下方程 (1) 给出。其中 β 指的是消光系数， L_∞ 是天空亮度。

$$L = L_0 e^{-\beta d} + L_\infty (1 - e^{-\beta d}) \quad (1)$$

基于 Koshmieder 公式，Duntley 提出了下列对比度衰减定律，有助于估计能见度：

$$C = C_0 (e^{-\beta d}) \quad (2)$$

$$d = \frac{\ln(C/C_0)}{\beta} \quad (3)$$

根据能见度 $C_0 = 1$ (黑体物体) 的定义，此外，国际照明委员会定义了对比度阈值 $C = 0.05$ 。通过替换这两个常数，(3) 式变为 $d = 3/\beta$ 。

基于这些数学表达式，Babari 等人 [5] 提出了一种非线性模型，该模型描述了对比度和可见度之间的映射函数。Li 等人 [6] 提出了一种有效的模型，该模型使用单张日光图像来估计观察到的气体的消光系数并计算场景可见度。然而，图像受到相机设置和天气条件（雾、霾等）的多种影响，这使得使用统计模型手动提取特征变得非常具有挑战性。

2.2 现有的深度学习方案

为了提高能见度估计模型的性能，近年来研究主要利用机器学习 (ML) 技术从数据中学习有用信息。这些方法不仅提升了预测精度，还为大气能见度研究提供了新视角和工具。传统方法依赖气象参数，但预测效果有限。因此，研究开始尝试使用标准 ML 模型，如 SVM、随机森林、梯度加速等，基于历史数据训练，学习模式和规律，从而更精确预测能见度变化。

然而，随着大数据时代的到来，传统的 ML 模型在处理复杂和多变的数据时显得力不从心。这时，深度学习（DL）技术应运而生，以其强大的特征提取能力和对大规模数据集的优秀分析能力，逐渐成为了各个领域的研究热点。在气象领域，深度学习已经被广泛应用于天气预报 [7]、风速估计 [8]、空气质量预报 [9, 10] 等多个方面。

3 研究方法

从文献综述中，我们得出如下结论：

(1) 如果数据集与综述里各类模型运用的相差较大，或数据量较小，都更适合进行迁移学习 [11]；

(2) 大多数深度学习模型仅基于表格数据或视觉信息进行学习，我们希望结合大气光学厚度（AOD）和相对湿度（RH）等物理属性作物理信息增强学习。这里有两个关键的公式分别启发性地揭示两个物理量与能见度的关系：

能见度（V）可以通过阿氏指数（ α ，描述了气溶胶散射的波长依赖性）来与气溶胶光学厚度（ τ ）建立关系 (4)。其中（ λ ）是光的波长。这个公式表明，随着 AOD 的增加，能见度会降低，而这种降低的速度取决于光的波长和阿氏指数。

$$V = \frac{3.912}{\tau} \lambda^{\alpha} \quad (4)$$

能见度（V）与 RH 之间的关系通常由一个经验公式来描述 [12]，公式 (5) 考虑了湿度导致的气溶胶颗粒的增长。 V_0 是在参考湿度水平下的能见度，而 γ 是一个系数，代表了气溶胶的水合增长因子。随着 RH 增加，能见度会趋向于因气溶胶颗粒的增长而降低。

$$V = V_0 e^{-\gamma(RH-100\%)} \quad (5)$$

所以我们试图利用从北京大学大气与海洋科学系获取的本地数据（包括天空图像视觉数据，以及能见度、AOD 和 RH 等表格数据）和预训练模型作迁移学习。

3.1 数据集介绍

出于数据可获得性考虑，本次研究所使用的数据均由组长从北京大学物理学院大气与海洋科学系获取，包括：

1. 使用鱼眼相机拍摄的全天空成像仪图片数据：数据以命名包含了年、月、日、时、分以及曝光种类信息。我们仅能获得 2018 年 12 月、2019 年 1 月、2 月和 5 月部分天数的数据，因此其日期分布比较局限。总计可用图片数量为 3360。
2. 使用前向散射仪记录的能见度表格数据。
3. 其他仪器测出的 AOD 和 RH 数据。形式同为日期-时间以及对应的数值。见图 4。

鱼眼相机拍摄图片如图 3所示。



图 3: 图片数据来自物理学院西楼楼顶全天空成像仪。以上为其中三张

获得以上三类数据后，我们的数据处理过程分为：

1. 掩码处理，见图 5。在鱼眼相机镜头中，圆形可见区域越靠近圆心处代表仰角越大的天空部分，而实际上位于图像边缘、代表仰角较小的天空部分才是与仪器所测得的能见度有较强代表性的区域，同时也是更具有实际应用价值的低空区域。为了使得模型学习更有效，我们对所有图片数据添加了黑色圆形掩码以遮盖高仰角天空部分。
2. 时间戳对齐。在数据的时间分辨率上，全天空成像仪的图片数据要大于后两类数据。为了形成适用于模型训练的数据，需要将能见度、AOD 和 RH 的数据在时间点上与图片的时间点对齐。进行此步操作时，发现 AOD 数据有大量缺失。后续在模型训练中，我们将使用直接清除、向上填充和使用 KNN 补全方法处理 AOD 缺失问题。而 RH 对齐时还进行了线性插值处理。




图 4: 左图: 北京大学物理学院西楼楼顶的前向散射能见度仪。
 右图: 能见度数据, 形式为日期-时间以及对应的能见度(单位为米)

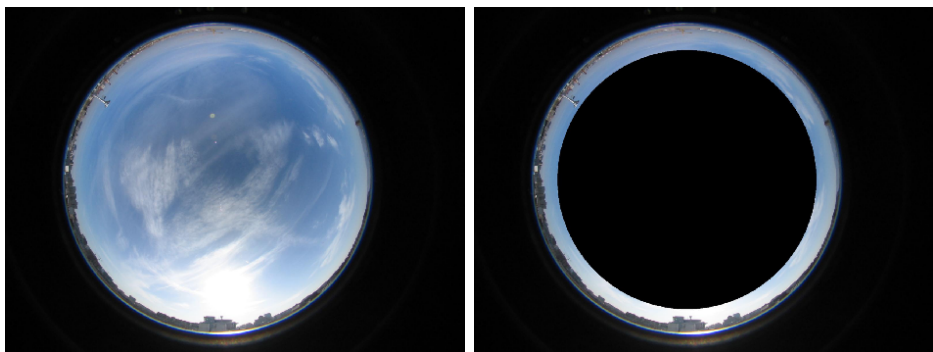


图 5: 原文与掩码后的图像对比

3. 训练集与测试集划分。将三类在时间戳上对齐的数据，每五个划分为一组，前四个作为训练数据，最后一个作为测试数据。故训练集、测试集比例为 4:1。

3.2 模型介绍

我们的小组分别独立地选择了三种方式完成该任务。这样的安排可以充分探索不同模型的能力，并在最终得到结果时互相对比，从中选取出最优的模型，并尝试解释不同模型之间的差异。

3.2.1 基于 InceptionV3 的微调

Inception v3 由谷歌研究员 Christian Szegedy 等人在 2015 年的论文 [13] 中提出。Inception v3 是 Inception 网络系列的第三个版本，它在 ImageNet 图像识别竞赛中取得了优异成绩，尤其是在大规模图像识别任务中表现出色。下图 6 展示了该网络的结构。




图 6: Inception V3 网络结构

考虑到 Inception V3 的优异表现，我们尝试以它作为模型编码器，在它的基础上微调并训练。我们的模型结构如下图 7。

使用不固定参数的 Inception v3 模型作为图像编码模型。将两种曝光模式的照片（image 0 和 image 1）编码，并将结果通过一维卷积层（3*3，padding=1，保证特征数量不变）进行特征图合并，得到最终的图像编码。

接下来是三个全连接层，其中数值特征（numerical features，包括月份、时刻与湿度、温度等）会在第一层和第二层与输入进行拼接（形成长度 2048+x 和长度 1024+x 的层输入），目的是进行多模态融合。第三层的输出将使用 sigmoid 激活，并乘以 15000 使其值域为 0-15000，也即实际能见度的范围。这样的设置便于后续损失的计算。

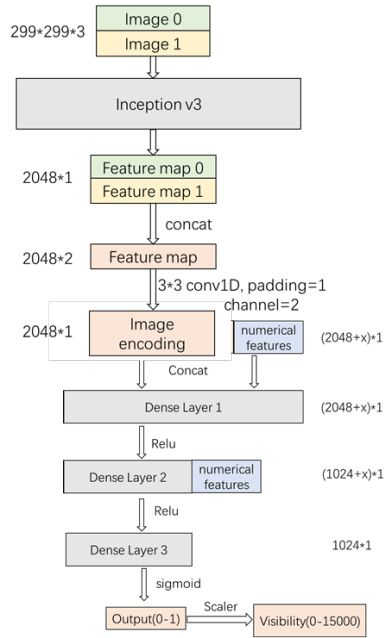


图 7: 基于 Inception V3 的网络结构




图 8: 基于 ViT 的网络结构

从结构图可以看到，模型使用一维卷积融合了两种曝光度的图片，并通过多次融合的方式与数值特征融合。

3.2.2 基于 DenseNet121 预训练模型搭建的网络

DenseNet 是一种由 Gao Huang 等人在 2016 年提出的深度卷积神经网络架构 [14]。与传统卷积神经网络（如 ResNet）不同，DenseNet 在网络层之间建立了更密集的连接，使得每一层都直接连接到所有先前的层。这种架构具有以下特点：密集连接、特征重用、更高的参数效率和更高效的梯度传播。

DenseNet 的这些设计思想使得它在许多图像分类任务中表现出色，尤其在参数效率和训练稳定性方面。模型输入是同一时刻的不同曝光度的图像在宽度上的拼接，之后经过一个预训练的 DenseNet121 之后得到高维特征向量，将它与 AOD、RH 拼接，共同通过 3 层全连接层得到预测值。模型结构如图 9。




图 9: 基于 Densenet 的模型结构

3.2.3 基于 vit-base-patch16-224 预训练模型搭建的网络

该模型基于 Google/vit-base-patch16-224 预训练模型 [15], 它是进入 Transformer 时代后训练的大模型, 具有远超以往模型的能力。

我们站在巨人的肩膀上, 不作过多的微调。以这个模型为编码器, 将输入尺寸为 1200x800 的彩色图片, 编码为 768 维的数值向量, 以供进一步的训练, 但在后续过程中不再调整编码器的权重。在图像编码的基础上, 搭建一个含有两层隐藏层的多层感知机, 神经元个数分别设置为 128 和 32, 权重初始化后即可用于训练。模型结构如前文图 8所示。

4 实验过程

三个模型分别由不同的组员搭建并完成实验。

设备方面: 基于 InceptionV3 的模型 (下简称 IV3) 在贝式计算 (Open-Bayes) 平台上完成; 基于 DenseNet121 的模型 (下简称 DN) 在 Kaggle 上完成; 基于 ViT 的模型 (下简称 VB) 在个人计算机上完成。

模型的训练过程中各个实验的设置参数有所区别, 以表格形式列出如下表 1。

模型	lr	epoch	batch size
IV3	5e-5	60	16
DN	1e-3	100	32
VB	1e-5	500	32

表 1: 模型参数设置

训练过程记录了训练集和验证集上损失函数值随训练轮次的变化, 整理如图 10。整体来看所有模型都在经过训练后收敛, 说明模型充分学习了训练集数据。




图 10: 各个模型在训练集和验证集上的损失变化

5 结果与分析

5.1 实验指标

训练完成后，我们在测试集上检验模型学习结果。我们综合考虑了 4 个指标：MSE，RMSE，MAE 和 R2。其中 MSE 是模型的损失函数，可以直接评估各个模型之间的差异。RMSE 与 MAE 是两个“同阶”的指标，能直观地反映估计值与真实值的误差。而作为回归任务，R2 定义如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{MSE}{Var}$$

它反映因变量的全部变异能通过回归关系被变量解释的比例，越接近 1 就代表拟合效果越好。因而这也是合适的评价指标。

5.2 实验结果

整理三个模型在测试集上的指标记录如下表 2

模型	MSE	MAE	RMSE	R2
IV3	2272271.31	233.526	521.796	0.981
DN	646072.59	499.326	803.786	0.968
VB	294710.87	294.498	513.871	0.980

表 2: 模型参数设置

首先，测试结果受随机数影响较大，250000-500000 的测试集 mse 表现都是较为常见的，在算力和时间允许的基础上，应当多次重复实验以获得更准确的评估。

其次，考虑到能见度范围（0-15000），这样的测试集 mse 是可接受的，能见度相差 1 千米并非很大的区别，而经过 MSE 放大后就会导致数万的差异。总而言之，我们从这个结果中可以认为，模型较好地完成了估计能见度的任务。

此外从表格中也可以看到，各个模型之间的差异是比较明显的。首先是 DN 模型，表现相对差，推测可能的原因有如下几点：

1. 没有对模型结构进行修改，只是将最后一个分类层转为 3 个全连接层进行微调。
2. 训练轮次不够。从模型训练历史来看，损失函数呈现波动下降的趋势是使用了余弦退火算法的原因。观察其趋势，模型还有进一步训练优化的空间，提升 epoch 数可能会有效提升模型效果。但由于算力和时间都有限，未能在任务截止之前充分实验
3. 对数据的处理方面，模型是直接将图片拼接后作为输入，考虑将两张图片在经过 DenseNet121 之后得到高维向量，再拼接可能会得到更好的表示效果。

其次是 IV3 模型，与 DN 相对地，它对模型整体进行了微调，并且将图像编码为特征图后再进行拼接，这正是上文提到的第三点可能的原因。若能进行多组实验，排除了随机因素对结果的影响后，可能可以证明这样的设计思路是更为合理的。

最后是 VB 模型，它的思路更为直接，将图像编码后作为输入，用于多层感知机的学习。虽然这个模型并没有微调编码器本身，但由于编码器是基于 Transformer 的大模型，结构上有优势。这使得编码器的输出本身就已经是非常好的表示，即使不再微调也能有很优秀的表现。它的表现稍逊色于进行过微调的 IV3 模型，这也是意料之中的。

此外需要提到的是，VB 模型由于没有微调过程，因此直接使用 ViT 输出编码结果即可，这部分耗时并不长，而后续仅仅是训练两层神经网络，这一部分的速度也是极快的，因此 VB 模型对算力的需求相对低很多。

5.3 消融实验

我们对自己设计的模型进行了一些基本的消融实验，以验证一些设计是有助于提升模型的表现的。

消融实验设计包括：

- 固定 Inception V3 模型参数，验证微调的影响
- 仅使用图像作为输入，验证引入物理特征的影响
- 不作图像处理，验证数据增强的影响

其中实验一针对 IV3 模型，实验 2、3 出于控制变量和节省时间的考虑，仅用 VB 模型进行对照实验。实验的结果整理见表 3²。

模型	实验项目	MSE	MAE	RMSE	R2
IV3	微调（原结果）	2272271.31	233.526	521.796	0.981
	固定编码器权重	545931.812	338.47	738.872	0.972
VB	仅图像	326663.1875	288.151	497.1529	0.9833
	图像 + 物理特征	301982.75	313.392	549.529	0.9796
	图像 + 数据增强	300810.843	328.985	548.462	0.979
	图像 + 数据增强 + 物理特征	294710.87	294.498	513.871	0.980

表 3: 消融实验结果

²部分结果与 PPT 中展示的有所差异，因为在展示后重做了部分实验。

从消融实验结果可以得到以下结论：

1. 不固定参数的设置是有效的，微调能显著提升模型的性能。
2. 引入物理特征有助于提升模型性能，但并不是决定性的。归根结底能见度是一个可以从图像就基本确定的数值，但引入有关物理特征是可行的，后续的工作可以尝试增加更多有关的物理特征来进一步提高模型性能。
3. 数据增强对本项目中相对较小的数据集是有效的，能改善模型的表现。但由于图像本身是由鱼眼相机拍摄的全景照片，因此翻转等数据增强手段对模型的帮助并没有那么大。但总归是有积极作用的。这也为我们指明了一个方向：扩大数据集，以充分发挥深度学习模型的强大威力。

6 后续工作

目前的工作存在多处有待优化的细节：

1. 全天空成像仪数据优化处理。该图片数据是鱼眼相机所成的圆形图片，所以可以考虑转化为更适合一般视觉深度学习模型的矩形等转换方式。
2. 数据量以及数据种类优化。更多的图片数据、以及更全面的能见度有关物理信息（例如 PM2.5/10）数据都将改善模型训练的结果。
3. 时间和算力充足的情况下，我们可以做更多实验以调整参数，并消除随机性对结果的影响。

7 小组分工

- 江丰捷，组长，负责课题拟定、进度管理、数据获取与准备、PPT 和报告（摘要、引言、文献综述、数据介绍、后续工作、总结、分工、致谢）撰写
- 黄柏喻，负责 Google/vit-base-patch16-224 模型的部署与训练，PPT（Google/vit-base-patch16-224 模型部分）和报告（Google/vit-base-patch16-224 模型部分、结果与分析）撰写

- 浦皓天, 负责 Inceptionv3 模型的部署与训练, PPT 和报告撰写 (Inceptionv3 模型部分)
- 张轩, 负责 DenseNet121 模型的部署与训练, PPT 和报告撰写 (DenseNet121 模型部分)

8 总结

本次研究从能见度的意义出发, 结合能见度视觉与物理信息相关性开展了应用不同的预训练模型进行物理信息增强的能见度估计实验, 均获得了较好的估计效果, 并得出掩码处理、物理信息增强等特色工作的有效性结论。

该研究工作聚焦于运用本地数据集作由相似工作指导下的特色研究, 有希望于引导在更大规模、专用性更强、适应性更高的数据集上的深度学习能见度估计方案的建设。预计算法成熟后, 将有客户端 (例如个人日常、智能驾驶和小型飞行任务等) 上作能见度估计任务的可能性。

致谢

感谢北京大学物理学院大气与海洋科学系博士生李沐谦、张震宇提供的本研究所需要的所有数据。感谢课程主讲老师孟凡提供的算力经费支持。

参考文献

- [1] J. N. Morden, F. Caraffini, I. Kypraios, A. H. Al-Bayatti, and R. Smith, “Driving in the rain: A survey toward visibility estimation through windshields,” *International Journal of Intelligent Systems*, vol. 2023, no. 1, p. 9939174, 2023.
- [2] “Meteorological service for international air navigation : annex 3 to the convention on international civil aviation,” Each ed. incorporates all amendments adopted by the Council ... all previous eds. of Annex 3.
- [3] B. Staats, “Mind the gap: Space resiliency advantages of high-altitude capabilities.,”
- [4] K. A. Ouadil, S. Idbraim, T. Bouhsine, N. C. Bouaynaya, H. Alfergani, and C. C. Johnson, “Atmospheric visibility estimation: a review of deep learning approach,” *Multim. Tools Appl.*, vol. 83, pp. 36261–36286, 2023.
- [5] R. Babari, N. Hautière, Éric Dumont, R. Brémond, and N. Paparoditis, “A model-driven approach to estimate atmospheric visibility with ordinary cameras,” *Atmospheric Environment*, vol. 45, no. 30, pp. 5316–5324, 2011.
- [6] Q. Li, Y. Li, and B. Xie, “Single image-based scene visibility estimation,” *IEEE Access*, vol. 7, pp. 24430–24439, 2019.
- [7] P. Hess and N. Boers, “Deep learning for improving numerical weather prediction of heavy rainfall,” *Journal of Advances in Modeling Earth Systems*, vol. 14, no. 3, p. e2021MS002765, 2022. e2021MS002765 2021MS002765.
- [8] Y. Han, L. Mi, L. Shen, C. Cai, Y. Liu, K. Li, and G. Xu, “A short-term wind speed prediction method utilizing novel hybrid deep learning algorithms to correct numerical weather forecasting,” *Applied Energy*, vol. 312, p. 118777, 2022.

- [9] L. Qi, M. Zhu, L. Wu, X. Pan, X. Tang, and Z. Wang, “Deep learning for air quality forecasts: a review,” *Current Pollution Reports*, vol. 6, pp. 1–11, 12 2020.
- [10] Z. Bilen and F. Bozkurt, “Comparison of different machine and deep learning techniques to predict air quality index: A case of kocaeli province,” in *2021 29th Signal Processing and Communications Applications Conference (SIU)*, pp. 1–4, 2021.
- [11] A. Hosna, E. Merry, J. Gyalmo, Z. Alom, Z. Aung, and M. A. Azim, “Transfer learning: a friendly introduction,” *Journal of Big Data*, vol. 9, 2022.
- [12] Z. S. L. Z. J. N. . H. X. Xia, F., “Analysis of long-term distributed autonomous orbit determination for beidou-3 satellites.,” *Journal of Geodesy*, 2024.
- [13] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, “Re-thinking the inception architecture for computer vision,” *CoRR*, vol. abs/1512.00567, 2015.
- [14] G. Huang, Z. Liu, and K. Q. Weinberger, “Densely connected convolutional networks,” *CoRR*, vol. abs/1608.06993, 2016.
- [15] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” *CoRR*, vol. abs/2010.11929, 2020.